

RAG检索增强生成技术入门简介

一、什么是RAG？

RAG的全称是检索增强生成，是一种结合了信息检索和大语言模型的技术。

它的核心思想是先从外部知识库中检索相关的信息，再把这些信息作为上下文提供给大模型基于私有知识生成回答，而不是完全依赖模型自身的预训练知识。

二、RAG的基本工作流程

1. 文档处理阶段：将上传的PDF、Word等文档进行文本提取和分块，再通过嵌入模型将文本块转换为向量，存入向量数据库。
2. 检索阶段：当用户提出问题时，将用户的问题也转换为向量，在向量数据库中相似度最高的Top-K个文本块作为相关上下文。
3. 生成阶段：将检索到的上下文和用户问题一起组装成提示词，调用大语言模型生成最终的回答，同时可以返回引用的来源原文。

三、RAG的主要优点

1. 减少大模型幻觉：因为回答是基于私有知识库的真实内容生成的，大大降低了大模型编造信息的概率。
2. 支持私有知识：可以直接使用企业或个人自己的文档作为知识库，不需要重新训练大模型。
3. 答案可溯源：可以直接定位到回答对应的原始文档片段，方便验证准确性。

四、常见应用场景

RAG技术目前广泛应用于智能客服、企业内部知识库问答、学术文献助手、法律文档分析等场景，是大模型落地最常用的技术方案之一。